ANKARA ÜNİVERSİTESİ
YZM212 MAKİNE ÖĞRENMESİ DERSİ

2. LABORATUVAR ÖDEVİ

MLE İLE AKILLI ŞEHİR PLANLAMASI

Hazırlayan: Enes CAN
Öğrenci Numarası: 24290628
Tarih: 15.03.2026

Bölüm 1: Teorik Çözümler

Bu çalışmada, bir dakikada geçen araç sayılarının Poisson dağılımına uyduğu varsayılmıştır. Poisson dağılımı, belirli bir zaman aralığında meydana gelen olay sayılarını modellemek için kullanılan ayrık bir olasılık dağılımıdır. Bu ödevde amaç, verilen trafik verilerine göre Poisson dağılımının parametresi olan λ değerini Maximum Likelihood Estimation (MLE) yöntemiyle tahmin etmektir.

Poisson dağılımının olasılık kütle fonksiyonu aşağıdaki gibidir:

$$P(K = k_i \mid \lambda) = \frac{e^{-\lambda}\lambda^{k_i}}{k_i!}$$

Burada k_i, i'inci gözlemi; λ ise dağılımın beklenen değerini ifade etmektedir.

Elimizde birbirinden bağımsız n adet gözlem olduğunu varsayalım. Bu durumda likelihood fonksiyonu şu şekilde yazılır:

$$L(\lambda) = \prod_{i=1}^{n} \frac{e^{-\lambda}\lambda^{k_i}}{k_i!}$$

Bu ifade düzenlenirse:

$$L(\lambda) = \frac{e^{-n\lambda}\lambda^{\sum_{i=1}^{n} k_i}}{\prod_{i=1}^{n} k_i!}$$

Likelihood fonksiyonunun logaritması alınarak log-likelihood fonksiyonu elde edilir:

$$\ell(\lambda) = \ln\big(L(\lambda)\big)$$

$$\ell(\lambda) = -n\lambda + \left(\sum_{i=1}^{n} k_i\right)\ln(\lambda) - \sum_{i=1}^{n} \ln(k_i!)$$

MLE yönteminde amaç, bu log-likelihood fonksiyonunu maksimum yapan λ değerini bulmaktır. Bunun için λ'ya göre türev alınır:

$$\frac{d\ell(\lambda)}{d\lambda} = -n + \frac{\sum_{i=1}^{n} k_i}{\lambda}$$

Maksimum noktayı bulmak için türev sıfıra eşitlenir:

$$-n + \frac{\sum_{i=1}^{n} k_i}{\lambda} = 0$$

Buradan:

$$\frac{\sum_{i=1}^{n} k_i}{\lambda} = n$$

$$\sum_{i=1}^{n} k_i = n\lambda$$

$$\hat{\lambda} = \frac{1}{n}\sum_{i=1}^{n} k_i$$

Sonuç olarak Poisson dağılımı için Maximum Likelihood Estimation ile bulunan parametre tahmini, örneklem ortalamasına eşittir:

$\hat{\lambda}$**= x̄**

Bu sonuç oldukça önemlidir. Çünkü Poisson dağılımında parametre tahmini doğrudan verilerin ortalamasına bağlıdır. Yani veri setindeki ortalama araç sayısı, aynı zamanda MLE ile elde edilen λ tahminidir.

Bu ödevde kullanılan trafik verisi aşağıdaki gibidir:

[12, 15, 10, 8, 14, 11, 13, 16, 9, 12, 11, 14, 10, 15]

Bu verilerin toplamı:

12 + 15 + 10 + 8 + 14 + 11 + 13 + 16 + 9 + 12 + 11 + 14 + 10 + 15 = 170

Toplam gözlem sayısı:

n = 14

Dolayısıyla λ tahmini:

$\hat{\lambda}$ = 170 / 14 = 12.142857

Yani teorik olarak elde edilen sonuç, Poisson dağılımının parametresinin yaklaşık olarak **12.142857** olduğunu göstermektedir.

Bölüm 2: Analiz ve Yorumlar

Bu bölümde, teorik olarak elde edilen λ değerinin Python ile sayısal yöntem kullanılarak da doğrulanması amaçlanmıştır. Bunun için negatif log-likelihood fonksiyonu tanımlanmış ve SciPy kütüphanesindeki optimizasyon araçları kullanılarak minimum nokta aranmıştır. Elde edilen sayısal sonuç, teorik olarak bulunan örneklem ortalaması ile aynı çıkmıştır.

Analitik çözüm sonucunda bulunan λ değeri:

λ = 12.142857

Sayısal optimizasyon sonucunda bulunan λ değeri de yaklaşık olarak:

λ = 12.142857

Bu durum, Poisson dağılımı için MLE yönteminin teorik sonucunu doğrulamaktadır. Başka bir ifadeyle, kod ile yapılan optimizasyon işlemi matematiksel türetme ile tamamen uyumlu bir sonuç vermiştir.

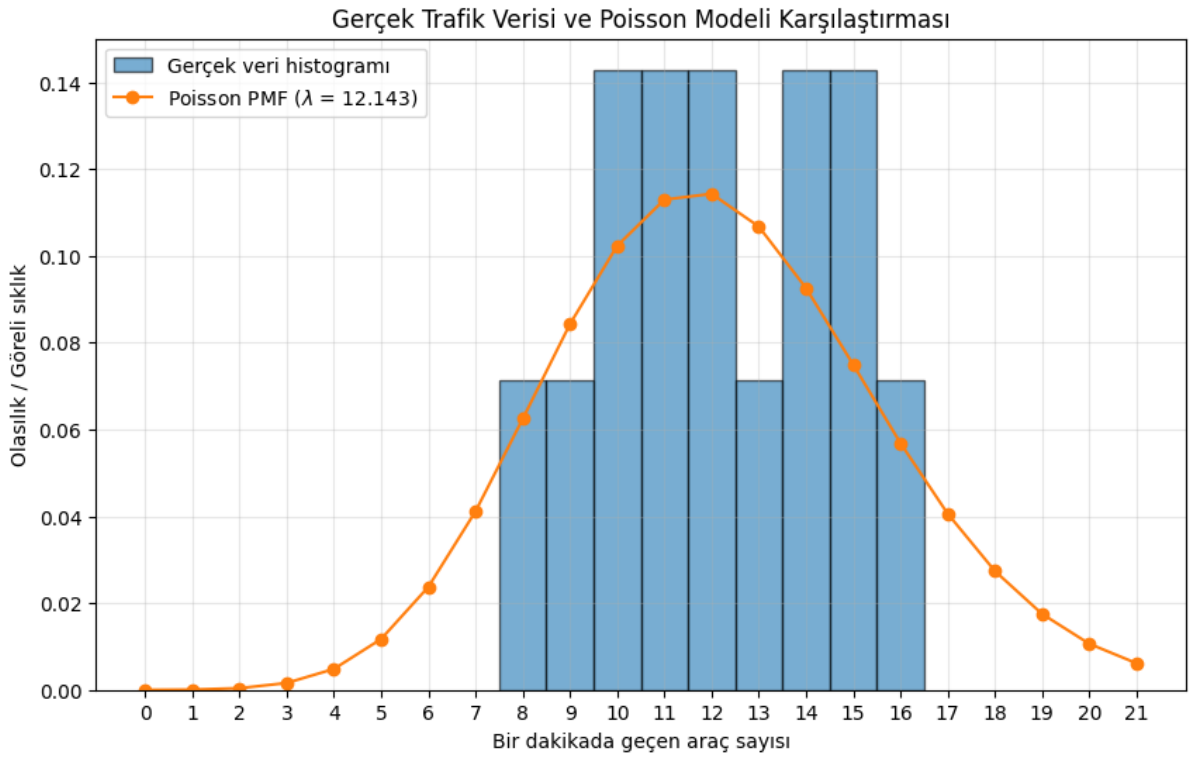

Grafiksel analizde veri histogramı ile tahmin edilen Poisson dağılımının olasılık kütle fonksiyonu aynı eksen üzerinde karşılaştırılmıştır. Histogram incelendiğinde gözlemlerin çoğunlukla 8 ile 16 arasında toplandığı görülmektedir. Özellikle 10, 11, 12,

14 ve 15 gibi değerlerin tekrar ettiği fark edilmektedir. Bu durum, verinin belirli bir merkez etrafında yoğunlaştığını göstermektedir.

Poisson PMF eğrisi incelendiğinde, λ = 12.142857 değeri ile çizilen dağılımın da veri histogramının genel yapısına benzer bir şekil sergilediği görülmektedir. Bu benzerlik, Poisson modelinin mevcut veri seti için makul bir yaklaşım sunduğunu göstermektedir. Yani bir dakikada geçen araç sayılarının Poisson dağılımı ile modellenmesi bu örnek veri için anlamlı görünmektedir.

Bu sonuç akıllı şehir planlaması açısından değerlendirildiğinde, şehir içi trafik yoğunluğunun belirli aralıklarda istikrarlı biçimde dağıldığı söylenebilir. Böyle bir model sayesinde belediyeler ya da trafik yönetim sistemleri, belirli zaman aralıklarında beklenen araç sayısını tahmin edebilir ve buna göre sinyalizasyon, yol kapasitesi veya denetim planlaması yapabilir.

Ancak burada dikkat edilmesi gereken önemli bir nokta, MLE yönteminin aykırı değerlere karşı hassas olmasıdır. Çünkü Poisson dağılımında λ tahmini doğrudan ortalama üzerinden hesaplanmaktadır. Eğer veri setine normalden çok daha büyük veya çok daha küçük bir gözlem eklenirse, ortalama ciddi biçimde değişebilir ve bu da modelin tüm yapısını etkileyebilir.

Bu durumu incelemek için veri setine 200 değerinde bir aykırı gözlem eklenmiştir. Yeni veri seti şu hale gelmiştir:

[12, 15, 10, 8, 14, 11, 13, 16, 9, 12, 11, 14, 10, 15, 200]

Bu durumda yeni toplam:

170 + 200 = 370

Yeni gözlem sayısı:

15

Dolayısıyla yeni λ tahmini:

$\hat{\lambda}$ = 370 / 15 = 24.666667

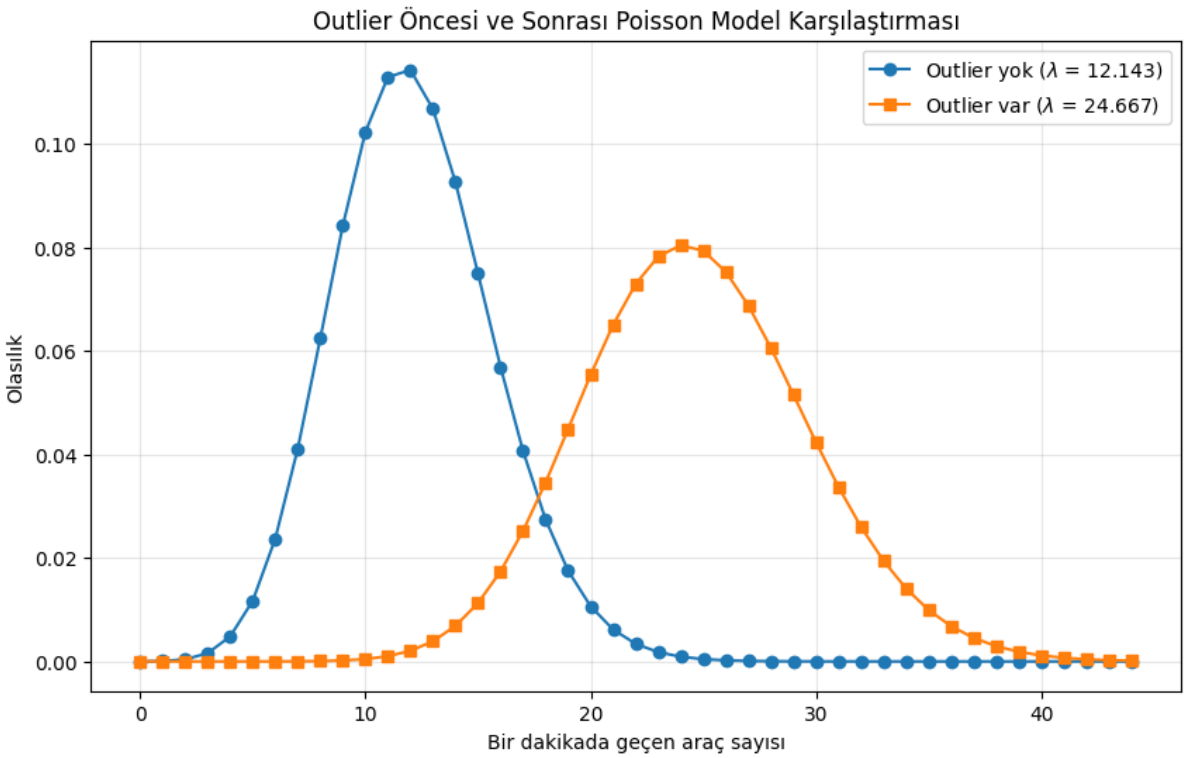

Görüldüğü gibi, yalnızca tek bir aykırı değer eklenmesine rağmen λ değeri yaklaşık 12.14'ten 24.67'ye yükselmiştir. Bu çok büyük bir değişimdir. Bu sonuç, MLE yönteminin özellikle ortalama tabanlı dağılımlarda aykırı değerlere oldukça duyarlı olduğunu açıkça göstermektedir.

Bu durumun gerçek hayattaki etkisi oldukça önemlidir. Örneğin trafik verilerinde sensör hatası, veri giriş yanlışı veya olağanüstü bir durum nedeniyle yanlışlıkla çok büyük bir değer sisteme girilirse, model şehirdeki normal trafik yoğunluğunu olduğundan çok daha yüksek tahmin edebilir. Bunun sonucunda gereksiz altyapı yatırımları, yanlış sinyalizasyon planları veya hatalı kapasite tahminleri yapılabilir.

Bu nedenle yalnızca MLE sonucuna güvenmek yeterli değildir. Model kurulmadan önce veri seti üzerinde aykırı değer analizi yapılmalı, veriler kontrol edilmeli ve gerekirse robust istatistiksel yöntemler değerlendirilmelidir. Aksi halde teorik olarak doğru olan bir yöntem, kirli veri nedeniyle pratikte yanıltıcı sonuçlar üretebilir.

Sonuç olarak bu çalışmada Poisson dağılımı için λ parametresinin MLE ile nasıl elde edildiği hem teorik hem de sayısal olarak gösterilmiştir. Analitik çözüm ile Python çıktılarının aynı sonucu vermesi yöntemin doğruluğunu kanıtlamaktadır. Ayrıca yapılan outlier analizi, veri kalitesinin model başarısı üzerindeki kritik etkisini ortaya koymuştur. Bu nedenle veri bilimi ve makine öğrenmesi uygulamalarında yalnızca model kurmak değil, aynı zamanda veriyi doğru analiz etmek ve temizlemek de büyük önem taşımaktadır.

Kaynakça

Bu çalışma, ders kapsamında verilen ödev yönergesi ve Poisson dağılımı ile Maximum Likelihood Estimation konularına ait temel istatistiksel bilgiler kullanılarak hazırlanmıştır.

İsteğe bağlı akademik kaynak eklemek için aşağıdaki eser yazılabilir:

Casella, G., & Berger, R. L. (2002). *Statistical Inference*. Duxbury.